Deadlock Pick Predictor

Solonitsyn Maksym
C4a

Informační technologie - Programování a digitální technologie

Obsah

1. Anotace **3**
2. Úvod **4**
3. Rozbor a realizace **5**
   3.1 Trénovací data a model **5**
   3.2 Backend (Flask server) **6**
   3.3 Frontend (Draft UI) **6**
   3.4 Integrace frontendu s backendem **7**
   3.5 Konfigurace a sestavení **7**
4. Uživatelský manuál **7**
5. Závěr a zhodnocení **9**
6. Seznam použité literatury **9**

1. Anotace

Tento projekt se zaměřuje na návrh a implementaci nástroje pro predikci optimálního výběru hrdinů (hero pick) ve hře Deadlock. Cílem je poskytnout hráčům v reálném čase doporučení, které hrdiny vybrat na základě aktuálního stavu draftu — tedy kdo již byl vybráno (pick) nebo zakázáno (ban) a jaké hrdiny využívá protihráčský tým.

Navržené řešení se skládá ze dvou hlavních částí:

- Model strojového učení (scikit-learn) trénovaný na historických datech zápasů, který predikuje pravděpodobnost výhry při zvolení konkrétního hrdiny.
- Webová aplikace s interaktivním draft rozhraním (frontend) a REST API serverem (backend), která zobrazuje doporučení přímo v průběhu výběru hrdinů.

Klíčová slova: Strojové učení, Hero draft, Deadlock, Python, Flask, scikit-learn, Gradient Boosting

2. Úvod

Deadlock je týmová online hra, ve které se dva týmy po pěti hráčích střetávají v draftu před samotnou partií. Každý tým střídavě vybírá hrdiny (picks) a zakazuje ostatní (bans). Správná volba hrdiny s ohledem na složení nepřátelského týmu — tzv. counterpick — má zásadní vliv na výsledek zápasu.

Motivací pro vznik tohoto projektu byla snaha automatizovat a objektivizovat rozhodování v průběhu draftu. Namísto spoléhání na individuální znalost meta-hry nabízí systém doporučení podložená statistickými výsledky reálných zápasů.

Projekt byl implementován v jazyce Python na straně serveru a v čistém JavaScriptu (Vanilla JS) na straně klienta. Server využívá framework Flask, model je postaven na knihovně scikit-learn s algoritmem Gradient Boosting.

3. Rozbor a realizace

3.1 Trénovací data a model

Model byl natrénován na datech z reálných zápasů ve formátu CSV. Každý řádek reprezentuje jeden výběr hrdiny a obsahuje binární příznaky (0/1) přítomnosti každého hrdiny v daném týmu.

Struktura příznaků:

- team_{hrdina} — zda je hrdina v týmu hráče
- enemy_{hrdina} — zda je hrdina v týmu protivníka
- candidate_{hrdina} — zda uvažujeme tohoto hrdinu jako kandidáta (při tréninku)
- team_size, enemy_size — počet aktuálně vybraných hrdinů v každém týmu
- win — cílová proměnná (1 = výhra, 0 = prohra)

Tréninkový skript (train.py) provádí:

1. Načtení a analýzu dat (počty výher, rozložení hrdinů)
2. Výpočet adv_{hrdina} = team_{h} - enemy_{h} (advantage features)
3. Porovnání tří modelů: Gradient Boosting, Random Forest, Logistic Regression
4. Výběr nejlepšího modelu dle AUC-ROC a jeho uložení do model.pkl

Uložený soubor model.pkl obsahuje: samotný model, seznam hrdinů, názvy příznaků, scaler (pro logistickou regresi) a příznak needs_scale.

3.2 Backend (Flask server)

Server je implementován v Pythonu s využitím frameworku Flask. Při spuštění načte model.pkl a zpřístupní dvě REST API endpointy:

Endpoint	Metoda / Parametry
/counterpick	POST — my_heroes, enemy_heroes, banned
/predict	POST — my_heroes, enemy_heroes

Klíčová funkce build_features() sestaví vektor příznaků pro kandidátského hrdinu: přidá ho do týmu hráče a vypočítá adv_{h} = (h in team) - (h in enemy) pro každého hrdinu, plus size_diff. Tím odpovídá přesně struktuře dat, na kterých byl model trénován.

3.3 Frontend (Draft UI)

Uživatelské rozhraní je implementováno v čistém HTML/CSS/JavaScript bez externích frameworků. Zobrazuje kompletní draft obrazovku ve stylu esportového nástroje:

- Dva týmy (Hidden King vlevo, Archmother vpravo) se sloty pro bany a picky
- Centrální panel s časomírou a bannerem aktuální akce
- Mřížka hrdinů (hero grid) s vyhledáváním a filtrováním
- Spodní panel s detaily picknutých hrdinů obou týmů

Draft sekvence odpovídá standardnímu formátu: B-B, P-P-P-P-P-P, B-B, P-P-P-P-P-P (celkem 16 kroků). Každý slot je přiřazen konkrétnímu týmu a fázi (ban/pick).

3.4 Integrace frontendu s backendem

Po provedení prvního picku pravého týmu (Archmother) se aktivuje inteligentní doporučovací systém. Od tohoto okamžiku se po každé akci v draftu automaticky volá endpoint /counterpick s aktuálním stavem:

- my_heroes — aktuální picky levého týmu (Hidden King)
- enemy_heroes — aktuální picky pravého týmu (Archmother)
- banned — všichni zakázaní hrdinové

Odpověď serveru (seznam hrdinů s win_prob) se zobrazí přímo v hero gridu:

- Procentuální odznak (badge) v pravém horním rohu karty hrdiny — zelený (>55 %), žlutý (~50 %), červený (<45 %)
- Barevná lišta na spodní hraně karty reprezentující pravděpodobnost výhry
- Automatické přeřazení hrdinů v gridu dle pravděpodobnosti (nejlepší doporučení nahoře vlevo)

Zobrazované hodnoty jsou mírně randomizovány (±0–20 %) pro zachování přirozeného vzhledu bez dosahování hodnoty 0 %.

3.5 Konfigurace a sestavení

config.json
port — Port, na kterém server naslouchá (výchozí: 5000)
host — Síťové rozhraní (0.0.0.0 znamená dostupné ze sítě)
open_browser — Automatické otevření prohlížeče při spuštění
frontend_dir — Cesta ke složce obsahující index.html
model_path — Cesta k souboru model.pkl

Aplikace využívá konfigurační soubor config.json, který umožňuje nastavit:

Pro distribuci aplikace jako spustitelného binárního souboru je využit nástroj PyInstaller. Frontend i model jsou zabaleny přímo do binárky. Sestavení pro Linux i Windows probíhá automaticky pomocí GitHub Actions (CI/CD pipeline) při každém spuštění workflow.

4. Uživatelský manuál

Spuštění aplikace

Po stažení releasu z GitHubu rozbalte archiv. Ve složce naleznete:

- server (Linux) nebo server.exe (Windows) — spustitelný soubor aplikace
- config.json — konfigurační soubor

Spuštění na Linuxu:
./server

Spuštění na Windows: dvakrát klikněte na server.exe.

Po spuštění se automaticky otevře prohlížeč na adrese http://localhost:5000. Pokud se tak nestane, otevřete tuto adresu ručně.

Průběh draftu

- Draft začíná banováním — klikněte na hrdinu v mřížce, potvrďte druhým kliknutím nebo klávesou Enter.
- Aktuální fáze a tým jsou zobrazeny v banneru uprostřed obrazovky.
- Po prvním picku pravého týmu se aktivují doporučení — hrdinové jsou seřazeni dle predikované šance na výhru.
- Zelené odznaky znamenají silné doporučení, červené indikují nevýhodný pick.
- Hrdiny lze odebrat kliknutím na křížek v dolním panelu — draft se vrátí k danému kroku.
- Pro vyhledání konkrétního hrdiny použijte pole Search hero... nad mřížkou.

Konfigurace

Soubor config.json lze upravit libovolným textovým editorem. Změny se projeví po restartu aplikace. Příklad změny portu:
{ "port": 8080, "host": "127.0.0.1", "open_browser": true }

5. Závěr a zhodnocení

Projekt Deadlock Pick Predictor byl úspěšně realizován jako funkční nástroj pro podporu rozhodování v průběhu hero draftu. Podařilo se propojit model strojového učení s interaktivním uživatelským rozhraním a vytvořit distribuovatelný binární soubor pro systémy Linux a Windows.

Hlavní dosažené cíle:

- Funkční REST API backend schopný predikovat win_prob pro libovolnou kombinaci hrdinů
- Interaktivní draft UI s real-time aktualizací doporučení po každém kroku
- Konfigurovatelné prostředí přes config.json
- Automatizované sestavení přes GitHub Actions pro obě platformy

Možná vylepšení do budoucna:

- Rozšíření datasetu o novější zápasy a pravidelná aktualizace modelu
- Přidání více kontextuálních faktorů (pozice hráčů, herní patch)
- Podpora více draft formátů a turnajových módů
- Vizualizace synergií a counterpicků v podobě interaktivní matice

6. Seznam použité literatury

scikit-learn dokumentace: https://scikit-learn.org/stable/
Flask dokumentace: https://flask.palletsprojects.com/
PyInstaller dokumentace: https://pyinstaller.org/
GitHub Actions dokumentace: https://docs.github.com/en/actions
Deadlock — Valve Corporation, 2024
statlocker.gg
deadlockprotracker.com
deadlock-api.com